

FUNDAÇÃO ESCOLA DE COMÉRCIO ÁLVARES PENTEADO
CAMPUS LIBERDADE
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

GABRIEL CARVALHO MOTA - 24026334
GUILHERME DE LIMA SIQUEIRA - 21010649
RODRIGO LUIZ MENEZES DOS REIS - 24025708
VITORIA LETICIA MACIEL DA SILVA - 24026593

PICMONEY
ENTREGÁVEL 2: CIÊNCIA DE DADOS
ETAPA 2: LIMPAR/UNIFORMIZAR OS DADOS

São Paulo, 2025

1 LIMPAR/UNIFORMIZAR OS DADOS

Após a seleção das colunas, identificamos diversos problemas de qualidade que precisavam ser tratados antes da integração com o banco MySQL. O processo de limpeza foi realizado em duas frentes: primeiramente em Excel com suporte de IA, e posteriormente no banco de dados através de Python/SQLAlchemy.

Tratamento Prévio em Excel + IA

Problemas Identificados:

1. **Nomes de estabelecimentos com caracteres corrompidos**
 - Exemplos: "Lojas de EletrÃ´nicos e Games" (deveria ser "Eletrônicos")
 - **Solução:** Mapeamento manual (DePara) em Excel para correção de nomes
2. **Categorização incorreta de estabelecimentos**
 - Exemplo: Academia classificada como "Igreja"
 - **Solução:** Utilização de **IA (ChatGPT/Claude)** para readequar automaticamente as categorias de cada estabelecimento com base no nome e contexto
3. **Dados geoespaciais inválidos (Latitude/Longitude)**
 - Problema: A maioria dos registros de latitude e longitude geravam coordenadas incorretas ou inexistentes no mapa
 - **Decisão:** Descartar essas colunas e utilizar apenas dados de **bairro** para análises geoespaciais (mais confiáveis e consistentes)
 - **Resultado:** Viabilizou o mapa de calor geoespacial sem erros de plotagem
4. **Formatação de valores monetários**
 - Problema: Valores em R\$ utilizam formato "." para separador decimal (padrão internacional)
 - **Solução:** Conversão para padrão brasileiro ",", para melhor legibilidade
 - Exemplo: 1000.50 → 1.000,50

Integração no MySQL

Após as correções iniciais, os dados foram **exportados para MySQL** utilizando Python/SQLAlchemy, onde foram aplicadas transformações estruturais para garantir integridade referencial.

Principais Desafios Resolvidos:

1. Chaves Primárias Inválidas

- Problema: A coluna celular era a única chave potencial, mas apresentava inconsistências e não podia relacionar todas as tabelas
- **Solução:** Criação de chaves primárias **inteiras sequenciais** (id_player, id_parceiros, id_cupom, etc.) para garantir unicidade e performance

2. Impossibilidade de JOINS entre Tabelas

- Problema: Sem chaves primárias consistentes, não era possível fazer relacionamentos (JOINS)
- **Solução:** Implementar estrutura relacional normalizada com 6 tabelas e chaves estrangeiras (FK)

3. Remoção de Duplicatas

- Método: .drop_duplicates() em cada tabela derivada
- Verificação: Testes comparativos entre Excel e MySQL para confirmar integridade

Validação e Testes

Para confirmar a integridade dos dados após a limpeza nós fizemos:

1. **Contagem de registros:** Comparação entre Excel e MySQL
2. **Deteção de duplicatas:** Verificação de registros únicos por tabela
3. **Integridade referencial:** Testes de chaves estrangeiras